



TECH CHALLENGE • FASE 2 • DATA ANALYTICS

Classificando a Qualidade de Vinhos com Machine Learning

Como dados físico-químicos de laboratório podem prever, de forma objetiva e escalável, quais vinhos atingirão o padrão premium.

Avaliar a qualidade de um vinho hoje é lento, caro e subjetivo

Hoje, a qualidade de um vinho é avaliada por especialistas humanos, por meio de degustação — um processo que depende da experiência do avaliador, não escala facilmente e pode variar de pessoa para pessoa.

A cada lote de produção já são coletadas medições de laboratório (acidez, açúcar, álcool, sulfatos etc.). A pergunta que este projeto responde:
esses números já bastam para prever a qualidade, antes mesmo da degustação?



Objetivo do projeto

Construir um modelo de Machine Learning que classifique cada vinho como:

Alta Qualidade

nota de especialista ≥ 7

Baixa / Média Qualidade

nota de especialista < 7

Medições de laboratório de vinhos tintos portugueses

1.143

amostras de vinho tinto analisadas

11

variáveis físico-químicas medidas
em laboratório

0

valores faltantes — base íntegra e
pronta para análise

13,9%


dos vinhos avaliados são
considerados de Alta Qualidade



Fonte: Wine Quality Dataset (Kaggle) — variáveis como acidez, açúcar residual, dióxido de enxofre, densidade, pH, sulfatos e teor alcoólico.

Ponto de atenção

Vinhos de alta qualidade são raros na base — e isso importa




Por que isso importa

Somente 1 em cada 7 vinhos da base é "Alta Qualidade".

Um modelo ingênuo poderia "acertar" 86% das vezes simplesmente dizendo que nenhum vinho é premium — e seria inútil na prática.

Por isso, avaliamos os modelos com métricas que enxergam além da taxa de acerto geral, garantindo que o modelo realmente aprenda a reconhecer os vinhos premium.


O que mais se relaciona com um vinho de alta qualidade?



Insight #1

O teor alcoólico é o sinal mais forte de qualidade

Vinhos de alta qualidade apresentam, em média, teor alcoólico visivelmente maior — provavelmente reflexo de uvas mais maduras e fermentação mais completa.



Insight #2

Excesso de acidez volátil derruba a qualidade percebida

Acidez volátil elevada indica presença de ácido acético — o composto responsável pelo gosto de "vinagre". É a variável com relação negativa mais forte com a qualidade.



Uma base íntegra, tratada com critério — não com força bruta



Sem dados faltantes

Nenhuma imputação foi necessária — a base já estava completa.



Valores extremos mantidos

Medições fora do padrão foram preservadas: podem representar lotes atípicos legítimos, não erros de coleta.



4 novas variáveis criadas

Combinações como "álcool ÷ acidez volátil" ajudam o modelo a capturar padrões que as variáveis isoladas não mostram sozinhas.



Separação justa entre treino e teste



80% dos dados treinam o modelo e 20% ficam de fora para testar sua capacidade de generalizar, preservando a proporção real de vinhos premium em ambos os grupos.

Da análise dos dados a quatro modelos comparados lado a lado



Resultados

O modelo Random Forest se destacou entre os quatro testados



Por que essa métrica?

A AUC mede a capacidade do modelo de separar corretamente vinhos premium dos demais, em qualquer ponto de corte de decisão — quanto mais perto de 1, melhor.

O Random Forest venceu porque combina os sinais de várias variáveis simultaneamente, capturando relações que um único indicador não revela.

Resultados

O que o modelo campeão entrega na prática

92%

das classificações do modelo estão corretas
no geral

94%

de confiança: quando o modelo aponta "Alta
Qualidade", raramente erra

47%

dos vinhos premium reais são capturados
pelo modelo hoje



Uma decisão de negócio, não só técnica: existe uma alternativa (SVM) que captura mais vinhos premium (72% em vez de 47%), mas com mais alarmes falsos. A escolha do modelo ideal depende de qual erro custa mais caro para a operação — vale uma conversa entre dados e negócio.

O que isso muda no processo produtivo

1

Colheita e fermentação

Monitorar o ponto de maturação da uva e a eficiência da fermentação para atingir teores alcoólicos mais consistentes — o fator mais associado a vinhos premium.

2

Controle sanitário

Reforçar boas práticas contra contaminação bacteriana, principal causa do aumento de acidez volátil, que é o fator que mais reduz a qualidade percebida.

3

Triagem inteligente de lotes

Usar o modelo como uma primeira triagem automática, priorizando a atenção dos enólogos para os lotes mais incertos e agilizando a aprovação dos lotes de alta confiança.



Próximos passos

- Testar modelos de boosting (XGBoost / LightGBM) para ganhos adicionais de performance
- Ampliar a coleta de amostras de vinhos premium para reduzir o desbalanceamento das classes
- Validar o modelo com dados de novas safras antes de uso em produção

Obrigado!

Perguntas e discussões são bem-vindas.