

TECH CHALLENGE 2

Relatório Executivo — Classificação da Qualidade de Vinhos

Até que ponto os números de um laboratório já sabem se um vinho vai ser premium? Este relatório usa dados físico-químicos de 1.143 vinhos tintos para responder essa pergunta e traduzir a resposta em decisões concretas de produção.

EMERSON HENRIQUE DE LIMA E SOUSA — RM 373751

MOACYR SOUZA BARROS — RM 373412

São Paulo
2026

Resumo Executivo

Será que os números que qualquer laboratório de vinícola já mede rotineiramente — acidez, açúcar, teor alcoólico — já contam sozinhos se um vinho vai ser considerado premium? Foi essa a pergunta que guiou este trabalho, e a resposta curta é: em boa parte, sim.

Analizamos 1.143 vinhos tintos, cada um com 11 medições físico-químicas de laboratório e uma nota de qualidade atribuída por especialistas. Depois de comparar quatro abordagens diferentes de classificação, o modelo vencedor acerta 92% das suas previsões e, mais importante para quem decide com base nele, quase não erra quando aponta que um lote é premium — de cada 100 vinhos que o modelo classifica como Alta Qualidade, cerca de 94 realmente são.

O achado mais útil, porém, não foi o número final: foi a confirmação estatística de algo que a intuição enológica já sugeria. Teor alcoólico e acidez volátil são, disparados, os fatores que mais separam um vinho comum de um vinho de destaque. Isso já é, por si só, um insumo de produção — com ou sem modelo.

Além dos números, este relatório também mostra visualmente como cada modelo raciocina — com uma árvore de decisão simplificada e um comparativo lado a lado de como os quatro modelos separam vinhos padrão de vinhos premium (Seção 7).

Indicador	Resultado
Vinhos analisados	1.143 amostras de vinho tinto
Vinhos de Alta Qualidade na base	159 (13,9% do total)
Abordagens comparadas	4 modelos de classificação
Modelo vencedor	Random Forest (ajustado)
Acerto geral do modelo vencedor	92,1%
Confiabilidade quando aponta "Alta Qualidade"	93,8%
Fator mais determinante da qualidade	Teor alcoólico

Link do repositório do projeto

https://github.com/Moacyrsouzab/fiap_analytics_postech_challenge2

Sumário

Resumo Executivo	2
1. Por que isso importa	4
2. Conhecendo a base de vinhos	4
2.1 A qualidade dos dados, antes de tudo	4
3. O que os números contam antes de qualquer modelo	5
3.1 O que mais se relaciona com a qualidade	5
3.2 Valores fora da curva	6
3.3 Um desequilíbrio que muda tudo	7
4. Preparando o terreno para os modelos	8
5. Colocando os modelos à prova	8
6. O que os resultados realmente dizem	9
6.1 Comparando os quatro modelos	9
6.2 Olhando por dentro dos acertos e dos erros	9
6.3 Uma checagem mais rigorosa: precisão-recall	10
6.4 O modelo está apenas decorando os dados?	11
7. Da análise à decisão	12
7.1 Como o modelo decide: uma árvore de decisão simplificada	12
7.2 Fronteiras de decisão: comparando os quatro modelos	13
7.3 O que mais pesa na decisão	13
7.4 Uma explicação mais rigorosa: SHAP	14
7.5 Um exemplo, vinho a vinho	15
8. Como isso foi construído	16
9. Conclusão: o que aprendemos e para onde vamos	17
Apêndice A — Especificações técnicas do experimento	18
Apêndice B — Checklist de aderência ao desafio	19

1. Por que isso importa

Toda garrafa de vinho carrega uma promessa. Quem compra confia que aquele rótulo vai entregar o que promete — e quem produz sabe que, na prática, nem todo lote sai igual, mesmo repetindo o mesmo processo.

Hoje, quem decide se um vinho é bom ou não são especialistas humanos, degustando. Funciona, mas tem um custo: leva tempo, depende de quem está avaliando naquele dia, e não escala — não é viável provar cada garrafa de um lote de milhares de unidades.

Só que, antes de qualquer degustação, o laboratório já mediu uma dezena de variáveis daquele vinho: acidez, açúcar, densidade, teor alcoólico. A pergunta que motivou este trabalho foi direta: esses números, sozinhos, já bastam para prever se aquele vinho vai ser considerado de alta qualidade?

Se a resposta for sim — mesmo que parcialmente — isso muda o jogo: dá para triar lotes automaticamente, direcionar a atenção dos enólogos para os casos realmente incertos, e agir sobre o processo produtivo antes mesmo da garrafa estar pronta.

Para tornar essa pergunta respondível por um modelo, transformamos a nota de qualidade — que os especialistas dão numa escala de 0 a 10 — em uma pergunta binária: esse vinho é Alta Qualidade (nota 7 ou mais) ou é Baixa/Média Qualidade (abaixo disso)?

2. Conhecendo a base de vinhos

Trabalhamos com 1.143 vinhos tintos, cada um com 11 medições físico-químicas de laboratório mais a nota atribuída por especialistas. É uma base de tamanho moderado, mas suficiente para treinar e comparar modelos com segurança estatística.

Variável	O que mede
Acidez fixa e volátil	Componentes ácidos do vinho — a volátil está ligada ao gosto de "vinagre" quando em excesso
Ácido cítrico	Contribui para frescor e equilíbrio de sabor
Açúcar residual	Açúcar que sobra após a fermentação
Cloretos	Teor de sal do vinho
Dióxido de enxofre (livre e total)	Conservante natural, controla oxidação e contaminação
Densidade e pH	Propriedades físicas gerais do líquido
Sulfatos	Conservante/antioxidante adicional
Teor alcoólico	Percentual de álcool — o fator que mais importa, como veremos
Qualidade	Nota do especialista (0 a 10) — nossa variável alvo

2.1 A qualidade dos dados, antes de tudo

Antes de qualquer análise, temos o hábito de auditar a base: conferir se falta alguma informação, se os tipos de dado fazem sentido e se há linhas repetidas. O resultado foi tranquilizador — nenhuma das 12 colunas tem valor faltando.

Encontramos algumas linhas duplicadas, e decidimos mantê-las. Em medições físico-químicas de vinho, dois lotes diferentes podem, por coincidência, apresentar exatamente os mesmos números arredondados — não é um erro de digitação, é o tipo de coincidência que esse tipo de dado permite. Removê-las sem motivo poderia jogar fora amostras legítimas.

3. O que os números contam antes de qualquer modelo

Antes de treinar qualquer modelo, passamos um tempo simplesmente olhando os dados — e alguns padrões já ficaram claros antes de qualquer algoritmo entrar em cena.




Figura 1 – Como cada variável físico-química se distribui na base.

3.1 O que mais se relaciona com a qualidade

Cruzando cada variável com a nota de qualidade, duas se destacaram com folga — e na direção oposta uma da outra.

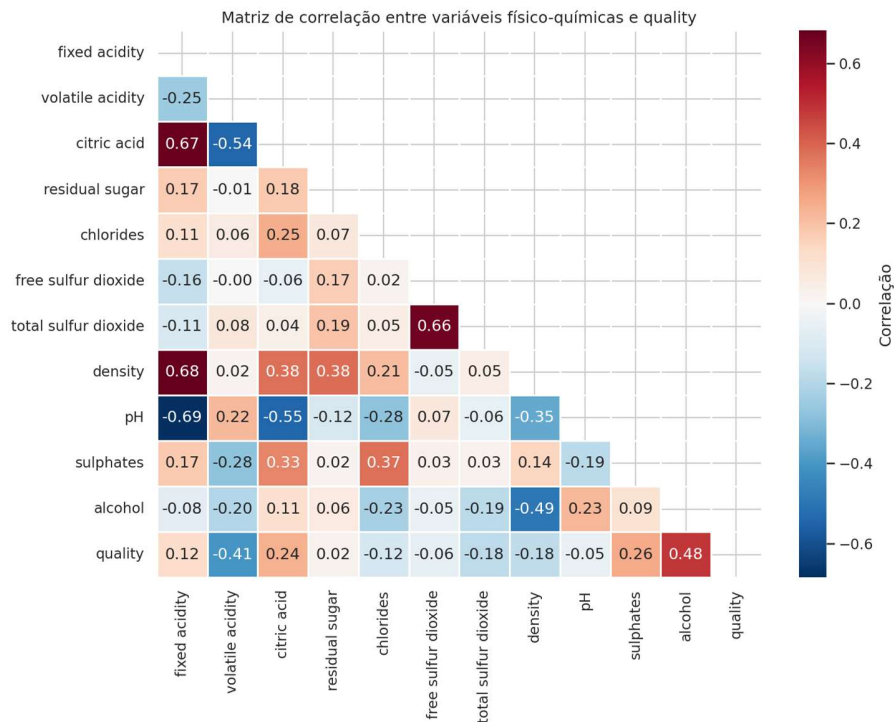


Figura 2 – Como cada variável se relaciona com as demais e com a nota de qualidade.

Teor alcoólico foi o achado mais forte. Vinhos de alta qualidade têm, em média, mais de um ponto percentual a mais de álcool do que os demais — provavelmente reflexo de uvas mais maduras e uma fermentação mais completa.

Acidez volátil foi o achado mais forte na direção contrária. Quanto maior a presença de ácido acético — o composto por trás do gosto de vinagre — menor a chance do vinho ser bem avaliado. Vinhos padrão da base têm, em média, 27% mais acidez volátil do que os premium.

Sulfatos e ácido cítrico também importam, com um peso menor: níveis adequados de sulfatos parecem ajudar a estabilidade do vinho, e o ácido cítrico contribui com frescor. Nenhum dos dois, porém, chega perto da força dos dois primeiros fatores.

3.2 Valores fora da curva

Como esperado em dados de laboratório, algumas variáveis apresentam medições bem acima ou abaixo da maioria — especialmente açúcar residual e cloretos.

Decidimos manter esses valores extremos em vez de removê-los. Em dados físico-químicos de vinho, um valor fora da curva costuma refletir uma variação real do processo produtivo, não um erro de medição — e pode ser justamente o tipo de lote atípico que interessa identificar, para o bem ou para o mal. Para

os modelos mais sensíveis a essas variações extremas (Regressão Logística, KNN e SVM), usamos uma normalização que reduz o impacto desses valores sem descartá-los.




Figura 3 – Cada variável comparada entre vinhos padrão e vinhos de alta qualidade.

3.3 Um desequilíbrio que muda tudo

Um detalhe da base moldou praticamente toda decisão metodológica deste projeto: vinhos de alta qualidade são raros. Apenas 159 dos 1.143 vinhos analisados — 13,9% — se enquadram nessa categoria.

Isso importa porque um modelo "preguiçoso" poderia simplesmente dizer que nenhum vinho é premium e ainda assim acertar 86% das vezes, sem ter nenhuma utilidade real. Por isso, em vez de olhar só a taxa de acerto geral, priorizamos métricas que mostram se o modelo realmente aprendeu a reconhecer os vinhos raros — e cuidamos para que treino e teste mantivessem a mesma proporção de vinhos premium.




Figura 4 – Distribuição da nota de qualidade original e da classificação binária usada no modelo.

4. Preparando o terreno para os modelos

Como a base não tinha valores faltando, o trabalho de preparação se concentrou em dois pontos: ajustar a escala das variáveis e criar novas informações a partir das que já existiam.

Criamos quatro variáveis novas, combinando informações que, sozinhas, diziam menos. A mais interessante combina justamente os dois fatores mais fortes encontrados na análise exploratória: a razão entre teor alcoólico e acidez volátil. Essa combinação teve uma relação com a qualidade mais forte do que qualquer uma das duas variáveis isoladamente — um indício de que o efeito conjunto dos dois fatores é mais informativo do que olhar cada um separadamente.

Variável criada	O que combina	Por que
Relação álcool / acidez volátil	Teor alcoólico ÷ acidez volátil	Reúne os dois fatores mais fortes em uma única medida
Acidez total percebida	Acidez fixa + acidez volátil	Aproxima o equilíbrio sensorial de acidez do vinho
Proporção de SO2 ativo	SO2 livre ÷ SO2 total	Indica quanto do conservante ainda está "em ação"
Doçura relativa	Açúcar residual ÷ teor alcoólico	Aproxima a percepção de doçura do vinho

Um cuidado metodológico importante: normalizamos os dados somente depois de separar o que seria usado para treinar o modelo do que seria usado para testá-lo — e o ajuste da escala foi calculado só com os dados de treino. Isso evita que o modelo "veja", ainda que indiretamente, informação dos dados que serão usados para avaliá-lo depois. O detalhamento técnico dessa etapa está no Apêndice A.

5. Colocando os modelos à prova

Testamos quatro abordagens diferentes de classificação, cada uma "pensando" o problema de um jeito distinto:

- Regressão Logística — traça uma fronteira relativamente simples e direta entre os dois grupos, fácil de interpretar.
- KNN — classifica cada vinho comparando-o aos vinhos mais parecidos com ele já vistos antes.
- SVM — desenha uma fronteira mais flexível entre os grupos, capaz de capturar padrões não lineares.
- Random Forest — reúne um comitê de várias pequenas árvores de decisão, que votam em conjunto.

Para evitar a armadilha de um modelo que apenas "decora" os dados de treino e vai mal diante de vinhos novos, testamos cada abordagem em pedaços diferentes da base repetidas vezes, simulando como ela se sairia diante de dados nunca vistos. Os dois modelos mais promissores (Random Forest e SVM) passaram, em seguida, por um refinamento adicional, testando diferentes configurações internas até chegar na versão mais equilibrada de cada um.

Os parâmetros exatos testados nessa etapa — e o restante da configuração técnica do experimento — estão documentados no Apêndice A, para quem quiser reproduzir o experimento passo a passo.

6. O que os resultados realmente dizem

6.1 Comparando os quatro modelos

Como o desequilíbrio entre as classes já era conhecido (Seção 3.3), a comparação priorizou métricas que enxergam além da taxa de acerto geral. Os resultados abaixo foram medidos sobre vinhos que nenhum dos modelos viu durante o treinamento.

Modelo	Acerto geral	Confiabilidade quando aponta "Alta"	Vinhos premium que identifica	Poder de separação (AUC)
Random Forest	92,1%	93,8%	46,9%	0,913
SVM	85,2%	47,9%	71,9%	0,880
Regressão Logística	79,0%	36,2%	65,6%	0,863
KNN	90,0%	71,4%	46,9%	0,821




Figura 5 — Poder de separação de cada modelo entre vinhos padrão e premium.

6.2 Olhando por dentro dos acertos e dos erros

O Random Forest venceu na maioria dos critérios, mas vale destacar um trade-off real entre ele e o SVM, porque a escolha entre os dois é uma decisão de negócio, não só técnica.

O Random Forest quase não erra quando diz que um vinho é premium (93,8% de confiabilidade), mas deixa passar mais da metade dos vinhos premium reais sem identificá-los. Já o SVM identifica uma fatia bem maior dos vinhos premium reais (71,9% contra 46,9%), só que com bem mais alarmes falsos pelo caminho.

Em outras palavras: se o custo maior for prometer qualidade premium e não entregar, o Random Forest é a escolha mais segura. Se o custo maior for deixar passar um vinho realmente bom sem identificá-lo, o SVM captura mais desses casos.




Figura 6 — Curvas de separação entre as classes para os quatro modelos.




Figura 7 – Acertos e erros de cada modelo, vinho a vinho, no conjunto de teste.

6.3 Uma checagem mais rigorosa: precisão-recall

A comparação por poder de separação (Figura 5) é a métrica mais tradicional, mas em uma base com apenas 13,9% de vinhos premium ela pode passar uma impressão mais otimista do que a real. Por isso, fizemos uma segunda checagem, focada exclusivamente na capacidade de cada modelo de acertar a classe rara — que é a que importa na prática.




Figura 8 – Precisão vs. abrangência de cada modelo, focando apenas nos vinhos premium.

A linha tracejada mostra o quanto um modelo aleatório acertaria (13,9%, a proporção real de vinhos premium). Todos os quatro modelos ficam bem acima dessa linha — evidência de que aprenderam um padrão real, não ruído — e a ordem de desempenho se mantém a mesma já vista antes: Random Forest à frente, seguido por SVM. Essa segunda checagem, mais rigorosa para o cenário desbalanceado, reforça a confiança no resultado.

6.4 O modelo está apenas decorando os dados?

Antes de seguir para a interpretação, vale uma pergunta direta e desconfortável: os modelos aprenderam um padrão real, ou estão apenas memorizando os dados de treino? Para responder isso, comparamos o desempenho de cada modelo nos dados que ele já viu (treino) com o desempenho em dados nunca vistos (teste). Uma diferença grande entre os dois é o sinal clássico de overfitting.

Modelo	Acerto no treino	Acerto no teste	Diferença
Regressão Logística	79,8%	79,0%	0,8 p.p.
KNN	89,8%	90,0%	-0,2 p.p.
SVM	88,9%	85,2%	3,7 p.p.
Random Forest	100,0%	92,1%	7,9 p.p.

O Random Forest chama atenção: acerta 100% dos casos no treino — memoriza literalmente cada vinho que viu — mas cai para 92,1% no teste. Isso é, tecnicamente, overfitting no sentido mais literal do termo, e decidimos não escondê-lo: é resultado direto de a busca de hiperparâmetros (Apêndice A) ter encontrado como melhor configuração uma árvore sem limite de profundidade.

Duas evidências, porém, mostram que esse overfitting não compromete o modelo na prática. Primeiro, a busca de hiperparâmetros testou explicitamente versões com profundidade limitada, e mesmo assim a versão sem limite venceu na validação cruzada — ou seja, mesmo memorizando o treino, essa configuração generaliza melhor para este conjunto de dados do que as alternativas mais conservadoras. Segundo, e mais importante: o desempenho no teste continua sendo o melhor entre os quatro modelos. Se o overfitting fosse prejudicial na prática, o resultado em dados novos teria caído, não permanecido à frente dos demais.

Registramos, ainda assim, como ponto de atenção para o futuro: com uma base maior ou dados de novas safras, vale reavaliar se limitar a profundidade das árvores melhora a estabilidade do modelo em produção — mesmo que, com os dados de hoje, a validação aponte na direção contrária.

7. Da análise à decisão

7.1 Como o modelo decide: uma árvore de decisão simplificada

A importância de variáveis mostra o quê mais pesa na decisão do modelo, mas não mostra como essa decisão é tomada passo a passo. Para isso, treinamos uma única árvore de decisão simplificada — rasa o suficiente para caber em uma página e ser lida de cima a baixo.

Essa árvore isolada acerta 71,2% dos casos, bem menos que os 92,1% do Random Forest completo — e essa perda de desempenho é esperada e intencional. O objetivo aqui não é performance, é interpretabilidade: o Random Forest é, na prática, um comitê de centenas de árvores como essa votando em conjunto. Olhar uma árvore isolada é como assistir a um único jurado explicando seu raciocínio, em vez do veredito coletivo do júri inteiro.




Figura 9 – Árvore de decisão simplificada (profundidade limitada a 3 níveis, apenas para fins ilustrativos).

Cada caixa representa uma pergunta sobre uma variável (por exemplo, "teor alcoólico é menor ou igual a determinado valor?"). Conforme a resposta, o caminho segue para um lado ou outro, até chegar a uma folha final com a classificação. As caixas em tons mais escuros de bordô concentram mais vinhos de Alta Qualidade; as mais claras, mais vinhos padrão. A primeira pergunta que a árvore faz — no topo, antes de qualquer outra — recai justamente sobre a variável mais discriminativa entre as duas classes, confirmando de forma visual o mesmo resultado já indicado pela importância de variáveis.

7.2 Fronteiras de decisão: comparando os quatro modelos visualmente

Os quatro modelos usam 15 variáveis ao mesmo tempo, e não é possível desenhar uma fronteira de decisão em 15 dimensões em uma página. Para tornar a comparação visual, treinamos versões simplificadas dos quatro modelos usando apenas as duas variáveis mais fortes — teor alcoólico e acidez volátil — o suficiente para desenhar a fronteira em duas dimensões.

Atenção: esta é uma simplificação para fins didáticos. A acurácia de cada modelo aqui é mais baixa do que a dos modelos completos, já que usa só 2 das 15 variáveis disponíveis. O objetivo não é comparar desempenho — isso já foi feito na Seção 6 — e sim mostrar como cada família de modelo "pensa" o problema de forma diferente.




Figura 10 – Como cada modelo separa vinhos padrão (dourado) de vinhos premium (bordô), usando só as duas variáveis mais fortes.

A Regressão Logística desenha uma fronteira reta — é um modelo linear por natureza, só consegue separar as classes com uma linha. O KNN desenha um contorno irregular, que segue de perto a distribuição local dos vizinhos mais próximos de cada ponto. O SVM desenha uma curva suave, buscando a margem mais larga possível entre as duas classes. O Random Forest desenha contornos em "degraus", característicos de um modelo baseado em divisões sucessivas — a mesma lógica da árvore da Figura 9, só que combinando muitas delas. Nenhuma fronteira é "errada"; são formas diferentes de resolver o mesmo problema, e é por isso que vale comparar mais de um modelo em vez de confiar cegamente no primeiro que funcionar.

7.3 O que mais pesa na decisão

Duas formas diferentes de olhar para os modelos — a importância de variáveis do Random Forest e os coeficientes da Regressão Logística — apontaram para o mesmo conjunto de fatores-chave. Isso é um bom sinal: dois modelos com lógicas matemáticas bem distintas concordando reforça que o achado é real, não um acaso de um método específico.




Figura 11 – Quais variáveis mais pesam na decisão do Random Forest.

Colocando os achados técnicos ao lado do que eles significam na prática:

O que encontramos	O que isso significa para a produção	O que sugerimos
Teor alcoólico é o fator mais determinante	Uvas mais maduras e fermentação mais completa tendem a gerar vinhos premium	Acompanhar de perto o ponto de colheita e a eficiência da fermentação

O que encontramos	O que isso significa para a produção	O que sugerimos
Acidez volátil tem a relação negativa mais forte	Está ligada a contaminação bacteriana durante a vinificação	Reforçar o controle sanitário no processo
Sulfatos ajudam, mas não de forma linear	Provavelmente existe uma faixa ideal de dosagem, nem pouca nem excessiva	Vale um estudo dedicado a essa faixa ideal
O modelo é confiável, mas conservador	Ele raramente erra ao apontar um vinho premium, mas deixa passar parte deles	Usar como triagem inicial, não como decisão final — reservando a avaliação sensorial para os casos incertos

Vale registrar um investimento de médio prazo que não depende de nenhum ajuste no modelo: como vinhos premium são raros na base (13,9%), ampliar a coleta de amostras desse tipo tende a melhorar a capacidade do modelo de identificá-los — hoje, essa é a principal limitação de todos os quatro modelos testados, não só do vencedor.

7.4 Uma explicação mais rigorosa: SHAP

A importância de variáveis da Seção 7.3 responde "o que mais importa, em média, para o modelo inteiro?". Ela tem, porém, uma limitação conhecida: quando duas variáveis são correlacionadas entre si — como teor alcoólico e a razão álcool/acidez volátil, criada na Seção 4 — a importância pode ficar "dividida" de forma enganosa entre elas.

Para uma leitura mais rigorosa, calculamos os valores de SHAP (SHapley Additive exPlanations), uma técnica com base matemática consolidada (a mesma teoria dos jogos por trás do Prêmio Nobel de Economia de 2012) que reparte a contribuição de cada variável de forma justa, vinho a vinho — não apenas na média geral.




Figura 12 – Impacto de cada variável na previsão, vinho a vinho. Vermelho = valor alto da variável; azul = valor baixo. Posição à direita empurra para "Alta Qualidade".

A leitura confirma o que já era esperado: para teor alcoólico, os pontos vermelhos (teor alto) se concentram do lado que empurra a previsão para "Alta Qualidade", e os azuis (teor baixo) do lado oposto — o mesmo padrão da análise exploratória (Seção 3.1), agora validado vinho a vinho, não apenas na média da base.

7.5 Um exemplo, vinho a vinho

Para tornar essa explicação mais concreta, isolamos um único vinho do conjunto de teste e mostramos exatamente como o modelo chegou à sua decisão — o tipo de explicação que se poderia apresentar a um enólogo questionando por que um lote específico recebeu determinada classificação.




Figura 13 – Decomposição da previsão para um vinho específico do conjunto de teste.

A leitura funciona como um extrato financeiro: partindo da previsão média do modelo para qualquer vinho, cada variável soma ou subtrai até fechar no resultado final para aquele vinho específico. Esse nível de detalhe é o que torna o modelo auditável — em vez de aceitar a previsão às cegas, é possível mostrar exatamente quais medições de laboratório levaram àquele resultado, o que ajuda tanto a validar o modelo internamente quanto a justificar uma decisão de triagem para alguém fora da equipe de dados.

8. Como isso foi construído

Para que este trabalho possa ser conferido e reproduzido por qualquer pessoa — não só por quem o escreveu —, alguns cuidados foram tomados desde o início:

- Uma função reutilizável de auditoria de qualidade dos dados, aplicada antes de qualquer análise, documentando nulos, tipos e valores únicos de cada coluna.
- Uma semente aleatória fixa em todo o experimento, garantindo que qualquer pessoa que rode o mesmo notebook chegue exatamente aos mesmos números.
- Um arquivo de dependências (requirements.txt) com as bibliotecas mínimas necessárias para reproduzir o ambiente.
- Separação clara entre dados brutos, notebook de análise e resultados gerados, seguindo a estrutura de repositório sugerida pelo desafio.

Como próximo passo de maturidade, recomendamos formalizar um dicionário de dados versionado e registrar o histórico de métricas a cada nova execução, para acompanhar eventual perda de desempenho do modelo ao longo do tempo — algo natural conforme novas safras e processos produtivos vão sendo incorporados.

9. Conclusão: o que aprendemos e para onde vamos

Voltando à pergunta que abriu este relatório — será que os números de laboratório já sabem, sozinhos, se um vinho vai ser premium — a resposta que os dados dão é: em boa parte, sim. O modelo vencedor identifica vinhos de alta qualidade com 93,8% de confiabilidade, e os dois fatores mais determinantes (teor alcoólico e acidez volátil) confirmam, com evidência estatística, o que a experiência enológica já apontava.

Isso não significa substituir o especialista humano. Significa dar a ele uma ferramenta de triagem: usar o modelo para separar rapidamente os lotes de alta confiança dos lotes que merecem atenção redobrada, liberando tempo e atenção para onde eles realmente fazem diferença.

Para a operação, isso se traduz em três frentes concretas: monitorar de perto o teor alcoólico e a acidez volátil durante a produção, já que são os fatores de maior impacto; usar o modelo como uma primeira triagem automática de lotes; e ampliar, ao longo do tempo, a coleta de amostras premium, hoje o principal fator que limita o quanto o modelo consegue identificar.

Próximos passos

- Testar abordagens de boosting (como XGBoost), que costumam ganhar desempenho adicional sobre o Random Forest em problemas parecidos com este.
- Ampliar a coleta de vinhos de Alta Qualidade — hoje a maior limitação de todos os modelos testados.
- Validar o modelo com dados de novas safras antes de qualquer uso em produção, já que o comportamento de uma safra pode não se repetir em outra.
- Decidir, junto com a área de produção, se o critério prioritário é confiabilidade (Random Forest) ou abrangência (SVM) — essa escolha depende do custo real de cada tipo de erro para o negócio, não é uma decisão puramente estatística.

Apêndice A — Especificações técnicas do experimento

Esta seção documenta as escolhas técnicas do experimento, para fins de reprodutibilidade e auditoria. O conteúdo aqui é intencionalmente mais denso do que o restante do relatório — o objetivo é permitir que qualquer pessoa com conhecimento técnico reproduza exatamente os mesmos resultados.

Modelos e configuração

Modelo	Biblioteca / configuração
Regressão Logística	scikit-learn LogisticRegression, class_weight='balanced', max_iter=1000
KNN	scikit-learn KNeighborsClassifier, n_neighbors=7
SVM	scikit-learn SVC, kernel='rbf', class_weight='balanced', probability=True
Random Forest	scikit-learn RandomForestClassifier, class_weight='balanced'

Validação e ajuste de hiperparâmetros

Todos os modelos foram encapsulados em um Pipeline do scikit-learn (padronização via StandardScaler + classificador), garantindo que a normalização fosse ajustada exclusivamente nos dados de treino. A validação inicial usou StratifiedKFold com 5 divisões (folds), preservando em cada divisão a mesma proporção de vinhos de Alta Qualidade da base original.

Random Forest e SVM passaram por busca de hiperparâmetros via GridSearchCV, otimizando para ROC-AUC:

- Random Forest: número de árvores (200, 400), profundidade máxima (sem limite, 8, 12) e número mínimo de amostras por folha (1, 3, 5).
- SVM: parâmetro de regularização C (0,5, 1, 5, 10) e coeficiente do kernel gamma ('scale', 0,01, 0,1).

Separação treino/teste

80% dos dados para treino e 20% para teste, com amostragem estratificada (stratify=y) para preservar a proporção de 13,9% de vinhos de Alta Qualidade em ambos os conjuntos. Semente aleatória fixa (random_state=42) em todas as etapas com componente aleatória.

Explicabilidade (SHAP)

Os valores de SHAP foram calculados com shap.TreeExplainer sobre o classificador RandomForestClassifier já ajustado (dados de teste padronizados pelo mesmo StandardScaler usado no treino). Como o modelo é de classificação binária, foi utilizada a fatia de valores correspondente à classe positiva (Alta Qualidade, índice 1) tanto no gráfico de resumo (summary_plot) quanto no gráfico de decomposição individual (waterfall).

Ambiente e dependências

Python 3, com pandas, numpy, scikit-learn, matplotlib, seaborn e shap como bibliotecas principais. As versões mínimas recomendadas estão documentadas no arquivo requirements.txt do repositório.

Apêndice B — Checklist de aderência ao desafio

Critério do desafio	Onde foi atendido
Compreensão do problema	Seção 1 — contexto de negócio e transformação da variável alvo em classificação binária.
Análise exploratória de dados	Seção 3 — distribuições, correlações justificadas, outliers e balanceamento de classes.
Pré-processamento de dados	Seção 4 — tratamento de dados faltantes, padronização e quatro variáveis derivadas.
Desenvolvimento de modelos	Seção 5 — quatro modelos treinados, validados e comparados.
Avaliação dos modelos	Seção 6 — métricas de comparação, matrizes de confusão, curva de separação (ROC/AUC), curva precisão-recall e checagem explícita de overfitting (treino vs. teste).
Interpretação dos resultados	Seção 7 — variáveis mais influentes, árvore de decisão simplificada, fronteiras de decisão, explicabilidade individual via SHAP e tabela de achados, implicações e ações.
Recomendações acionáveis	Seções 7 e 9 — recomendações de produção e próximos passos.
Reprodutibilidade	Seção 8 e Apêndice A — auditoria de dados, semente fixa e especificações técnicas completas.
Apresentação executiva	PPT/PDF em anexo no repositório, com narrativa de dados voltada a público executivo.
Vídeo executivo	Roteiro de até 5 minutos preparado, em linguagem executiva.